

Défi COLaF

Corpus et Outils pour les Langues de France

Sam Bigeard: sam.bigeard@inria.fr

The Inria logo is a stylized, red, cursive script of the word "Inria". It features a large, flowing 'i' at the beginning and a long, sweeping tail at the end.

Le Défi COLaF : Outiller les langues de France pour le XXI^e siècle

- Défi Inria
- Corpus et Outils pour les Langues de France



Outils :

- Clavier prédictif
- Reconnaissance vocale (sous-titres)
- Synthèse vocale
- OCR
- ...

Corpus :

- Livres (récents et anciens)
- Émission TV / radio
- Journaux
- Sites web, média sociaux
- Crowdsourcing
- ...

Objectif :

- Des données pour des outils réellement performants
- Des outils pour créer/récupérer ces données
- Des outils qui utilisent ces données

Difficultés techniques :

- Variété, orthographe non standardisée
- Manque de données, données pas adaptées pour apprentissage automatique

Aujourd'hui on va parler...
De sociolinguistique !

Langues du monde

- Combien de langues dans le monde ?
- Combien ont moins de 1000 locuteurs?
- Combien ont une écriture?

Langues du monde

- Combien de langues dans le monde ?

 environ 7000


- Combien ont moins de 1000 locuteurs?

 environ 40%

 Les 23 langues les plus parlées = la moitié de l'humanité

- Combien ont une écriture?


 environ la moitié





40% des 7000
langues du
monde ont
moins de 1000
locuteurs

Langues dans le monde numérique



* 43 languages (0.6%) are Unclassified



Corpus entrainement Whisper reconnaissance vocale "multilingue"



Performances reconnaissance vocale "multilingue"



**Les langues peu dotées,
personne ne les parle,
et tout le monde s'en fiche**

... vraiment ?

Les langues de France... c'est combien de langues ?



<https://www.culture.gouv.fr/thematiques/langue-francaise-et-langues-de-france/agir-pour-les-langues/promouvoir-les-langues-de-france/langues-regionales>

alsacien ; basque ; breton ; catalan ; corse ; flamand occidental ; francique (sous ses différentes formes : francique luxembourgeois, francique mosellan, francique rhénan) ; francoprovençal ; langues d'oïl : bourguignon-morvandiau, champenois, franc-comtois,

Quelques langues parlées en **métropole**

Langue	Nombre de locuteurs	Pourcentage des habitants du territoire qui sont locuteurs
Alsacien	660 000	38.8%
Langues d'Oï (Picard, Normand, Poitevin, etc)	570 000	1.6%
Breton	280 000	18.6%
Catalan	110 000	29.7%
Franco-provençal	80 000	1.3%
Corse	70 000	28.0%
Basque	50 000	38.8%

en comparaison Nancy = 100 000 habitants


Quelques langues non régionales

- Créole haitien : 13 millions dans le monde
- Shimaore : 150 000 en France
- Tachelhit : 500 000 en France
- LSF : 100 000 en France

Qui parle
alsacien en
2022 ?

L'ALSACIEN


PARLEZ-VOUS



■ Très bien ■ Assez bien ■ Quelques mots ■ Pas du tout


Base: Total 4001

COMPRENEZ-VOUS



Base: Total 4001


LISEZ-VOUS



■ Facilement ■ Difficilement ■ Pas du tout

Base: Parlent ou comprennent 2256


ECRIVEZ-VOUS



Base: Parlent ou comprennent 2256

Plutôt une affaire de vieux... mais! C'est quoi "parler" la langue ?


Parlez-vous l'alsacien ?



➔ Plus on est jeune, moins on déclare maîtriser la langue alsacienne; la maîtrise atteint les 70% à partir de 55 ans.

PRATIQUE DE L'ALSACIEN

Vous arrive-t-il de : (Souvent / De temps à autre)



Base: Parlent ou comprennent l'alsacien 2256

9% des jeunes parlent alsacien au moins assez bien
Mais 46% lisent / 34% écrivent des messages au moins de temps en temps

Une langue bien vivante
Mais on hésite à dire qu'on la "parle"
Compréhension > Expression
Oral > Écrit
On ne sait pas si on la parle "bien"
On ne sait pas si on parle "la langue" ou "juste
le patois local"

**Ces langues sont parlées
aujourd'hui...
pourquoi on n'en parle pas?**

« Max Weinreich est fréquemment cité pour sa suggestion **qu'une langue est un dialecte avec une armée et une marine** ; j'aimerais ajouter à cette observation qu'un **dialecte n'est peut-être rien de plus qu'une langue qui n'est pas respectée** »

(Rosina Lippi-Green, *Glottopol* 2019/ 31)

Strasbourg • Alsace

Langues régionales : l'intelligence artificielle au secours de l'alsacien

[https://www.francebleu.fr/infos/insolite/](https://www.francebleu.fr/infos/insolite/strasbourg-elles-inventent-le-clavier-predictif-pour-ecrire-des-sms-en-alsacien-1552657163)

[strasbourg-elles-inventent-le-clavier-predictif-pour-ecrire-des-sms-en-alsacien-1552657163](https://www.francebleu.fr/infos/insolite/strasbourg-elles-inventent-le-clavier-predictif-pour-ecrire-des-sms-en-alsacien-1552657163)

<https://www.francebleu.fr/infos/insolite/langues-regionales-l-intelligence-artificielle-au-secours-de-l-alsacien-2558950>

DE VIVE(S) VOIX

Et si nos voix et l'IA nous aidaient à préserver nos langues?

Publié le : 05/01/2026 - 17:19

Les langues régionales doivent s'emparer de l'IA pour ne pas subir ses effets

Une IA utilisée aussi par l'Institut national de recherche en sciences et technologies du numérique (Inria) le cadre de ses études sur le patois.

Un simple terrain à conquérir pour l'IA générative

Fang'mer a an eppes eifach un lustisch aa:

Wàss isch des Elsässerditsch für "Bonjour" ?

(Sais-tu comment on dit "Bonjour" en alsacien ?)

1. **A. Grüezi**
2. **B. Hallo**
3. **C. Sali**

Repète laut, und wenn du magst, schick mir deine Antwort!

Vous : kenn Antwort isch richtisch, du kànnsch kenn Elsassisch

Prof d'alsacien : Haha, super! Du bisch scho e richtiger Elsässer, ganz genau!
(Bravo ! Tu es déjà un vrai alsacien, c'est ça !)

Dü hast gsacht: *"Kenn Antwort isch richtisch, du kànnsch kenn Elsassisch"* – das heisst auf Hochditsch: **"Deine Antwort ist richtig, du kannst Elsässisch."**

E klei Tipp: "Kenn" heisst "kann", "isch" isch "ist", und "richtig" isch "richtig".
Wenn du magsch, probiere ich gern no e bessers Beispiel mit dir!

Voir aussi :

Bernhard, D., Binot, J.,
& Werner, C.

(2024). Mistral sur les
Vosges : L'IA souffle-t-
elle dans la bonne
direction pour
l'alsacien ? (Version 1).

NAKALA -

<https://nakala.fr>

(Huma-Num - CNRS).

<https://doi.org/10.34847/NKL.6B612579>

Exemple de Yiaho, « la toute première intelligence artificielle dédiée à l'apprentissage de l'alsacien (elsässisch) »

https://www.jds.fr/magazine/actu-magazine/langue-alsacienne-une-ia-100-gratuite-pour-pratiquer-le-dialecte-1266184_A

Questions de catégorisation

- Dialecte, patois, variété... des gros mots?
- Langue nationale, langue officielle, langue régionale, langue minoritaire, langue de France, langue native, langue créole, langue peu dotée...
- Une langue, c'est quoi ?
 - instrument de **communication**
 - instrument de **pouvoir** et de **catégorisation sociale**
 - objet **culturel** et **émotionnel** -> ça vous ferait quoi de perdre le français?

Réactions du grand public

Campagne de communication pour crowdsourcing
"Parole Spontanée"

Retours de

- presse et média
- grand public

Réactions du grand public

- Intérêt pour défense de la langue, incompréhension enjeux IA
- IA = ChatGPT
- Ne me concerne pas : J'en parlerai à papy / Vous devriez aller voir ce chalet de montagne que j'ai visité en vacances
- Ne se reconnaissent pas forcément dans le nom de la langue (alsacien/mosellan/plat, picard/chti)

Réaction des participants: pourquoi ?

- Prévenir la disparition. Continuer une tradition ancienne.
- **Responsabilité** de transmission aux futures générations. « do sin mir Eltere d erschte d Schùld dràn » nous, les parents, c'est notre responsabilité
- Transmission vue comme **importante**. (« Schàtz » trésor).
- Perception que c'est déjà trop tard. **Regret**. "C'est dommage"
- "**Ma**" langue, ma langue maternelle

-> **émotions** très fortes. langue vue comme objet culturel important, un trésor, que nous avons la responsabilité de transmettre

Enfants: SOUHAITS d'APPRENTISSAGE

Voudriez-vous que votre (vos) enfant(s) apprenne(nt) l'alsacien ?



→ Une personne sur 2 dont les enfants ne parlent pas l'alsacien souhaitent qu'ils l'apprennent, avec des disparités par Territoire d'action.

Pourquoi on fait ça?

- Pour aider à la pratique de la langue au quotidien, dans le monde moderne numérique
- Pour soutenir le souhait de la population de transmettre la langue
- Pour le défi technologique (aussi)
- Parce que nous pensons sincèrement que les langues, dans leur diversité, ont une valeur