




L'IA et les langues

Il faut quoi pour qu'un ordinateur apprenne une lanuge ?


MATh.en.JEANS

23 mars 2026


Centre Inria de l'Université de Lorraine
Sam Bigeard

Moi


- Doctorat en linguistique
- Ingénieur de recherche à l'Inria
- Spécialiste en traitement automatique des langues
- Plus précisément en langues peu dotées



Les langues



Les langues




- Combien de langues dans le monde ?
- ... environ 7000
- Combien ont moins de 1000 locuteurs ?
- ... environ 40 %
- Les 23 langues les plus parlées = la moitié de la population mondiale
- Combien ont une écriture ?
- ... environ la moitié

Les langues

Le pays où on parle le plus
de langues en parle
combien ?

840 langues en
Papouasie Nouvelle Guinée

Et en France, combien de
langues ?



la France : plus de 50 langues


LES LANGUES RÉGIONALES EN FRANCE MÉTROPOLITAINE



Guyane : 10 langues natives


Nouvelle Calédonie : 29 langues natives

Les langues





- Combien de langues des signes dans le monde ?
- ... environ 300
- Combien de locuteurs des langues des signes dans le monde?
- ... 72 millions
- (population française = 67 millions)
- 4% des français de moins de 20 ans ont une déficience auditive

L'IA, c'est quoi?



Comment réfléchit l'ordinateur?

- On dit à l'ordinateur comment faire
- On donne des exemples à l'ordinateur et il apprend



On dit à l'ordinateur exactement quoi faire



"Si un mot de cette liste est présent dans le message de l'utilisateur, alors présente lui cette pub"


- + facile à mettre en place
- + explicable et corrigeable
- marche seulement pour des tâches explicables

Autres exemples :

- calculs mathématiques
- génération de texte simple :
météo, horoscope

"Demain, il fera ____ degrés à
____"

Méthodes IA



IA = Apprentissage automatique

"Fais ça, et débrouille toi"

On donne une grande quantité d'exemples
l'ordinateur apprend à généraliser à partir des exemples


C'est quoi une voiture?



Inria

C'est quoi une voiture?

- Impossible à définir avec des règles simples !
- Donc on fait de l'apprentissage
- Donc il faut beaucoup d'exemples



Méthodes IA



Grande famille de méthodes qui servent à faire plein de choses

- Reconnaissance image : repérer une tumeur sur une radio, reconnaître les panneaux routiers, reconnaissance faciale ...
- Jouer à des jeux, adversaires jeux vidéos
- Reconnaissance vocale : sous-titrage automatique
- Recherche de chemin : directions GPS, déplacement des personnages dans un jeu vidéo ...
- ...

Sous le capot, méthodes très différentes !

Traitement automatique des langues



Domaine qui produit les technologies linguistiques
= technologies qui utilisent la langue
avec ou sans IA

- Clavier prédictif
- Correction orthographique
- Traduction automatique
- Synthèse de la parole
- Transcription de la parole
- Génération de texte

Méthodes IA

- + Peut faire des tâches complexes non explicables
- Jamais 100% correct
- Difficile à expliquer ou corriger -> problème éthique
- Nécessite beaucoup de données
- Pour les plus complexes : très coûteux, très nocif pour l'environnement




Chat GPT

Générateur de texte = Clavier prédictif



Chat GPT



Coût d'apprentissage de GPT-4 :

28,800,000 kW/h = consommation annuelle d'électricité de 12 500 français

6,912,000 kilos de CO2 = faire rouler une voiture pendant 28 millions km, soit presque 700 fois la circonférence de la Terre

Ça coûte cher -> il faut pouvoir se faire de l'argent avec !

référence <https://www.linkedin.com/pulse/carbon-impact-large-language-models-ai-growing-cost-vaidheeswaran-fcbhc>

Inria

Les données, elles viennent d'où ?

- Se servir sur internet (crawl)
- Être un hébergeur de données (Google, Apple...)
- Crowdsourcing (volontaire ou forcé)
- Archives institutionnelles (TV, journaux...)
- Enquêtes linguistiques


Langues peu dotées

Peu dotées... en technologie. Mais pourquoi?

Moins de locuteurs ça veut dire :

- Moins de clientèle
- Moins de données
- Plus de variété dans la langue

Reconnaissance vocale



Combien de temps faut-il à un enfant pour apprendre à parler?

à 14h par jour pendant...

4 ans : 20 440 heures


10 ans : 51 100 heures

Pour la machine, pour apprendre la reconnaissance vocale

+ ou - selon vous?

réponse : 438 000 heures (solution commerciale en anglais "Whisper")

Reconnaissance vocale



Locuteurs alsaciens : 660 000 personnes

Heures d'entraînement Whisper : 680 000 heures

même si tous les locuteurs s'enregistraient 1 heure,
ce ne serait pas suffisant !

Nos recherches = Inventer des méthodes moins gourmandes
en données (et en électricité)

En résumé



- L' "IA" c'est plein de techniques différentes, certaines anciennes et efficaces, certaines récentes et très coûteuses
- Les générateurs de texte traitent des volumes énormes de données : c'est cher, et ça ne marche que pour les plus grosses langues
- Il y a 7000 langues dans le monde, moins de 10 sont bien couvertes par les technologies linguistiques
- Nos recherches : équiper les 6990 langues restantes



Merci !

Questions